



Practica II Modulo 3

PROYECTO DE MACHINE LEARNING APLICADO

a Políticas Públicas — Encuesta de Hogares 2025

casos 1 :Análisis de la Deserción Escolar en Bolivia

Postulante: Roger Choque Viscarra

*Factores sociodemográficos, económicos y geográficos
asociados a la no asistencia escolar*

Caso de estudio	Caso 1 — Deserción Escolar
Dataset	Encuesta de Hogares 2025 (EH2025)
Fuente	Instituto Nacional de Estadística de Bolivia
Población analizada	11,117 escolares (5-19 años)
Tasa de no asistencia	53.5%
Mejor modelo ML	Random Forest (AUC = 0.734)
Técnicas aplicadas	Random Forest + Regresión Logística + K-means

*Practica II Machine Learning aplicado a Políticas Públicas.
Análisis basado en microdatos anonimizados de la EH2025 del INE Bolivia.
Uso exclusivamente académico.*

Índice

1. Resumen Ejecutivo	3
2. Introducción y Contexto	4
3. Metodología	5
4. Parte 1: Preprocesamiento y Fusión de Datos	6
4.1 Carga de archivos .sav	6
4.2 Análisis exploratorio básico	7
4.3 Selección de variables clave	8
4.4 Construcción de la variable objetivo	9
4.5 Ingeniería de características	10
4.6 Fusión de datasets	11
5. Parte 2: Análisis Exploratorio y Visualización	12
5.1 Gráfico de barras comparativo	12
5.2 Relación edad-asistencia	13
5.3 Mapa interactivo Folium	14
5.4 Clustering K-means	15
6. Parte 3: Modelo de Machine Learning	16
6.1 Definición del problema	16
6.2 Regresión Logística	17
6.3 Random Forest	17
6.4 Evaluación y comparación	18
6.5 Importancia de variables	19
7. Parte 4: Hallazgos y Recomendaciones de Política Pública	20
8. Conclusiones y Limitaciones	22
9. Citación y Fuente	23

1. Resumen Ejecutivo

Este estudio analiza los factores que influyen en la deserción escolar en Bolivia utilizando los microdatos de la Encuesta de Hogares 2025 (EH2025) del Instituto Nacional de Estadística. La población analizada comprende **11,117 niños, niñas y adolescentes entre 5 y 19 años**, de los cuales el **53.5%** no asiste actualmente a ningún centro educativo. Este indicador, que combina la no matriculación con la deserción posterior, revela una problemática educativa estructural que requiere intervención prioritaria del Estado boliviano en coordinación con los gobiernos subnacionales.

El análisis identifica **patrones geográficos claros**: Chuquisaca (75.8% de no asistencia) y Tarija (66.4%) presentan las tasas más altas, seguidas por Oruro, Cochabamba y Beni. Por el contrario, La Paz muestra la tasa más baja (27.0%), actuando como un outlier positivo que merece estudio cualitativo complementario. La segmentación mediante clustering K-means permite agrupar los nueve departamentos en tres perfiles de riesgo educativo: alto, medio y bajo, facilitando la focalización territorial de políticas públicas.

Mediante un modelo de **Random Forest** con validación estratificada (80/20), se obtuvo un **AUC-ROC de 0.734** y una precisión del 67.1%, superando a la regresión logística (AUC = 0.673). Las variables más importantes identificadas son: la ubicación departamental (especialmente La Paz como factor protector), el ingreso per cápita del hogar, los años de estudio del jefe o jefa de hogar, el hacinamiento y la edad del estudiante. Estos hallazgos sugieren que la deserción no responde a un único factor, sino a una combinación de desventajas territoriales, socioeconómicas y familiares que se refuerzan mutuamente.

Hallazgos clave

- **Brecha geográfica:** La Paz presenta una tasa de asistencia 48 puntos porcentuales superior a Chuquisaca (72.9% vs 24.2%).
- **Edad crítica:** La asistencia cae drásticamente entre los 14 y 19 años, marcando la transición a secundaria.
- **Trabajo infantil:** Los estudiantes que trabajan presentan tasas de no asistencia significativamente mayores.
- **Educación parental:** Cada año adicional de estudio del jefe/a de hogar se asocia con mayor probabilidad de asistencia.
- **Zona urbana-rural:** La zona rural presenta 9.6 puntos porcentuales más de no asistencia que la urbana.

2. Introducción y Contexto

La educación es un derecho humano fundamental reconocido por la Constitución Política del Estado Plurinacional de Bolivia (Art. 17) y desarrollado en la Ley de la Educación N° 070 (2010), que establece la obligatoriedad de la educación desde el nivel inicial en familia comunitaria hasta el nivel secundario. Pese a este marco normativo, Bolivia mantiene desafíos persistentes en cobertura, permanencia y calidad educativa, particularmente en zonas rurales, comunidades indígenas y entre poblaciones en situación de pobreza.

La **deserción escolar** —entendida como el abandono del sistema educativo antes de completar el nivel obligatorio— es un fenómeno multidimensional que responde a factores individuales, familiares, económicos, culturales y geográficos. Sus consecuencias se proyectan a lo largo de toda la vida del individuo: menores ingresos laborales, mayor precariedad laboral, peor estado de salud, menor participación ciudadana y reproducción intergeneracional de la pobreza. A nivel agregado, la deserción reduce la productividad nacional, limita la capacidad de innovación del país y aumenta la presión sobre los sistemas de protección social.

La EH2025, aplicada a una muestra representativa de hogares bolivianos, ofrece una oportunidad excepcional para estudiar este fenómeno con granularidad fina. Sus microdatos permiten combinar información a nivel individual (edad, sexo, idioma, autoidentificación étnica), del hogar (ingresos, composición, equipamiento, servicios básicos) y contextual (departamento, zona urbana/rural). Esta riqueza de datos habilita el uso de técnicas de Machine Learning para identificar patrones no triviales y construir modelos predictivos que orienten la focalización de políticas públicas.

Pregunta de investigación: ¿Cuáles son los factores sociodemográficos, económicos y geográficos que más influyen en la deserción escolar en Bolivia, y cómo pueden estos hallazgos orientar políticas educativas focalizadas?

3. Metodología

3.1 Datos y unidad de análisis

Se utilizaron los microdatos de la EH2025 del INE Bolivia, específicamente los módulos de **Persona** (39,485 registros, 276 variables) y **Vivienda** (12,726 hogares, 64 variables). La unidad de análisis es el **individuo en edad escolar (5-19 años)**, resultando en una muestra final de 11,117 observaciones tras filtrar por edad y fusionar ambas tablas mediante la clave compartida folio (identificador de hogar).

3.2 Variable objetivo

La variable **asistencia_escolar** (binaria) se construyó combinando dos preguntas de la EH2025: (i) si la persona se matriculó en el año lectivo 2025 (s03a_04) y (ii) si actualmente cursa clases o se encuentra en vacaciones (s03b_10 y s03b_12). Se considera que un estudiante **asiste (1)** si se matriculó y continúa cursando o está en vacaciones pedagógicas; se considera que **no asiste (0)** si no se matriculó o si se matriculó pero abandonó. Esta definición captura tanto la exclusión inicial como la deserción intra-anual.

3.3 Ingeniería de características

Se construyeron variables derivadas para capturar dimensiones relevantes: **hacinamiento** (personas por cuarto), **índice de servicios básicos** (suma binaria de acceso a agua, electricidad y baño), **log-ingreso per cápita del hogar**, **años de estudio del jefe/a de hogar** (proxy de capital cultural parental), y variables binarias para material de vivienda adecuado, internet, autoidentificación indígena e idioma materno. Las variables categóricas (departamento y zona) se codificaron mediante one-hot encoding.

3.4 Técnicas analíticas

- **Análisis exploratorio (EDA):** estadística descriptiva por departamento, zona, sexo y edad.
- **Visualización geográfica:** mapa interactivo Folium con tasas departamentales.
- **Clustering:** K-means (k=3) sobre departamentos con PCA para visualización 2D.
- **Modelos predictivos:** Regresión Logística (baseline) y Random Forest (n=200, profundidad=12).
- **Evaluación:** división estratificada 80/20, métricas accuracy/precision/recall/F1/AUC-ROC.
- **Interpretabilidad:** importancia de variables por impureza (Gini) del Random Forest.

4. Parte 1: Preprocesamiento y Fusión de Datos

4.1 Carga de archivos .sav

La EH2025 se distribuye en formato SPSS (.sav). Usamos la librería **pyreadstat** para leerlos directamente en pandas, preservando los metadatos (etiquetas de variables y valores) que serán útiles para la interpretación posterior.

```
# =====
# 0. CONFIGURACIÓN INICIAL
# =====

import os, sys, warnings, json
import numpy as np
import pandas as pd
import pyreadstat
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm
import seaborn as sns
from pathlib import Path

warnings.filterwarnings('ignore')

# Configuración de fuentes y estilo
plt.rcParams['font.sans-serif'] = ['DejaVu Sans', 'Liberation Sans', 'sans-serif']
plt.rcParams['axes.unicode_minus'] = False
plt.rcParams['figure.dpi'] = 110
plt.rcParams['savefig.dpi'] = 150
sns.set_style("whitegrid", {'axes.grid': True, 'grid.alpha': 0.3})

# Rutas del proyecto
PROJECT_ROOT = Path("../")
DATA_DIR = PROJECT_ROOT / "data"
OUTPUTS_DIR = PROJECT_ROOT / "outputs"
IMAGES_DIR = OUTPUTS_DIR / "imagenes"
IMAGES_DIR.mkdir(parents=True, exist_ok=True)

# Paleta institucional boliviana
PALETTE = {
    'primary': '#0B5394', # azul institucional
    'secondary': '#38761D', # verde
    'accent': '#B45F06', # ámbar
    'danger': '#990000', # rojo
    'neutral': '#5F6368',
}
```

Proyecto elaborado Roger Choque Viscarra

```
# --- 1.1 Carga de archivos .sav ---
persona_df, persona_meta = pyreadstat.read_sav(
    DATA_DIR / "EH2025_Persona.sav", apply_value_formats=False)
vivienda_df, vivienda_meta = pyreadstat.read_sav(
    DATA_DIR / "EH2025_Vivienda_1.sav", apply_value_formats=False)
equipamiento_df, _ = pyreadstat.read_sav(
    DATA_DIR / "EH2025_Equipamiento.sav", apply_value_formats=False)
discrim_df, _ = pyreadstat.read_sav(
    DATA_DIR / "EH2025_Discriminacion.sav", apply_value_formats=False)
gastos_noali_df, _ = pyreadstat.read_sav(
    DATA_DIR / "EH2025_Gastos_No_Alimentarios.sav", apply_value_formats=False)

print(f"Persona:          {persona_df.shape[0]:,} filas x {persona_df.shape[1]}
columnas")
print(f"Vivienda:         {vivienda_df.shape[0]:,} filas x {vivienda_df.shape[1]}
columnas")
print(f"Equipamiento:      {equipamiento_df.shape[0]:,} filas x
{equipamiento_df.shape[1]} columnas")
print(f"Discriminación: {discrim_df.shape[0]:,} filas x {discrim_df.shape[1]}
columnas")
print(f"Gastos No Ali:   {gastos_noali_df.shape[0]:,} filas x
{gastos_noali_df.shape[1]} columnas")
```

Resultado de la carga: la tabla Persona contiene 39,485 registros con 276 variables; la tabla Vivienda contiene 12,726 hogares con 64 variables. Las demás tablas (Equipamiento, Discriminación, Gastos No Alimentarios) se cargan para análisis complementarios pero no se utilizan en el modelo principal del Caso 1.

4.2 Análisis exploratorio básico

Inspeccionamos tipos de datos, valores faltantes y etiquetas de variables. El módulo Persona tiene 276 variables, de las cuales seleccionaremos las relevantes para el análisis de deserción escolar.

```
# --- 1.2 Análisis exploratorio básico ---
print("Tipos de datos en Persona:")
print(persona_df.dtypes.value_counts())

print("\nValores faltantes (top 10) en Persona:")
print(persona_df.isnull().sum().sort_values(ascending=False).head(10))

# Diccionario de etiquetas de variables
var_labels = {**persona_meta.column_names_to_labels,
              **vivienda_meta.column_names_to_labels}
print(f"\nTotal de etiquetas de variables: {len(var_labels)}")

# Mostrar algunas etiquetas relevantes
print("\nEjemplos de etiquetas:")
for k in ['s01a_02', 's01a_03', 's03a_04', 's03b_10', 's06a_06']:
    print(f" {k}: {var_labels.get(k, 'N/A')}")
```

Las etiquetas del módulo Persona revelan que la variable s01a_02 corresponde al sexo, s01a_03 a la edad, s03a_04 a la matriculación escolar, s03b_10 a la asistencia actual y s06a_06 al material del piso de la vivienda. Estas serán las variables clave para construir nuestra variable objetivo y los predictores del modelo.

4.3 Selección de variables clave

De las 276 variables de Persona y 64 de Vivienda, seleccionamos las relevantes para el análisis de deserción escolar según la pregunta de investigación. La selección se basa en: **(i)** características individuales (edad, sexo, idioma, etnia, asistencia escolar); **(ii)** características del hogar (ingreso, hacinamiento, servicios básicos); **(iii)** contexto geográfico (departamento, zona urbana/rural); **(iv)** variables parentales (educación y ocupación del jefe/a de hogar).

```
# --- 1.3 Selección de variables clave ---
# Variables de Persona (a nivel individuo)
persona_cols = [
    'folio', 'nro', 'depto', 'area', 'factor', 'upm', 'estrato',
    's01a_02', # Sexo
    's01a_03', # Edad
    's01a_05', # Parentesco con jefe/a de hogar
```

Proyecto elaborado Roger Choque Viscarra

```
's01a_08', # Primer idioma (lengua materna)
's01a_09', # Autoidentificación indígena
's03a_01', # Sabe leer y escribir
's03a_02a', # Nivel educativo más alto aprobado
's03a_04', # Se inscribió/matriculó este año (clave)
's03a_06a', # Nivel en que se matriculó
's03b_10', # Actualmente pasa clases (clave)
's03b_12', # Vacaciones / receso
'aestudio', # Años de estudio
's04a_01', # Trabajó la semana pasada
's04b_12', # Categoría ocupacional
's04d_22a', # Ingreso total ocupación principal
's04c_17a', # Salario líquido
]
persona_sel = persona_df[persona_cols].copy()
print(f"Persona seleccionada: {persona_sel.shape}")

# Variables de Vivienda (a nivel hogar)
vivienda_cols = [
    'folio', 'depto', 'area', 'totper',
    's06a_03', # Material paredes
    's06a_05', # Material techos
    's06a_06', # Material pisos
    's06a_07', # Procedencia agua
    's06a_09', # Tipo baño
    's06a_10', # Desagüe baño
    's06a_12', # Energía eléctrica
    's06a_15', # Combustible cocina
    's06a_16', # Número de cuartos
    's06a_17', # Cuartos para dormir
    's06a_19', # Internet
    's06a_02a', # Alquiler estimado (proxy riqueza)
]
vivienda_sel = vivienda_df[vivienda_cols].copy()
print(f"Vivienda seleccionada: {vivienda_sel.shape}")
```

4.4 Construcción de la variable objetivo

Renombramos las variables con códigos opacos (s01a_02, s06a_06, etc.) a nombres interpretables. Luego construimos la variable **asistencia_escolar** combinando las preguntas de matriculación y asistencia efectiva. La población objetivo son las personas de 5 a 19 años (edad escolar según Ley 070/2010 ampliada).

```
# --- 1.4 Renombrado de variables ---
rename_persona = {
    's01a_02': 'sexo',          # 1=Hombre, 2=Mujer
    's01a_03': 'edad',
    's01a_05': 'parentesco',
    's01a_08': 'idioma_materno', # 1=Español, otros = originario
    's01a_09': 'indigena',      # 1=Sí, 2=No
    's03a_01': 'lee_escribe',    # 1=Sí, 2=No
    's03a_02a': 'nivel_educ',
    's03a_04': 'se_matriculo',
    's03a_06a': 'nivel_matricula',
    's03b_10': 'asiste_clases',
    's03b_12': 'en_vacaciones',
    'aestudio': 'anios_estudio',
    's04a_01': 'trabajo',
    's04b_12': 'categoria_ocup',
    's04d_22a': 'ingreso_lab',
    's04c_17a': 'salario_liq',
}
persona_sel = persona_sel.rename(columns=rename_persona)

rename_vivienda = {
    's06a_03': 'mat_pared',
    's06a_05': 'mat_techo',
    's06a_06': 'mat_piso',
    's06a_07': 'procedencia_agua',
    's06a_09': 'tipo_banio',
    's06a_10': 'desague_banio',
    's06a_12': 'electricidad',
    's06a_15': 'combustible_cocina',
    's06a_16': 'n_cuartos',
    's06a_17': 'n_cuartos_dormir',
    's06a_19': 'internet',
    's06a_02a': 'alquiler_estimado',
}
vivienda_sel = vivienda_sel.rename(columns=rename_vivienda)
```

```
# --- 1.5 Construcción de la variable objetivo ---
# Filtrar población en edad escolar (5-19 años)
```

Proyecto elaborado Roger Choque Viscarra

```
edad_min, edad_max = 5, 19
persona_sel['edad'] = pd.to_numeric(persona_sel['edad'], errors='coerce')
mask_edad = persona_sel['edad'].between(edad_min, edad_max)
print(f"Población en edad escolar ({edad_min}-{edad_max} años): "
      f"{mask_edad.sum():,} personas")

pob_escolar = persona_sel[mask_edad].copy()

# Función para construir asistencia_escolar
def compute_asistencia(row):
    sm = row['se_matriculo']
    ac = row['asiste_clases']
    ev = row['en_vacaciones']
    # Si se matriculó este año (1=Si)
    if sm == 1:
        # Si está en vacaciones o actualmente cursa → asiste
        if ac == 1 or ev == 1:
            return 1
        else:
            return 0 # Se matriculó pero ya no asiste → desertor
    else:
        # No se matriculó
        return 0

pob_escolar['asistencia_escolar'] = pob_escolar.apply(compute_asistencia, axis=1)

# Verificar distribución
n_asiste = (pob_escolar['asistencia_escolar'] == 1).sum()
n_no_asiste = (pob_escolar['asistencia_escolar'] == 0).sum()
print(f"\nDistribución de la variable objetivo:")
print(f" - Asiste (1):      {n_asiste:,} ({n_asiste/len(pob_escolar)*100:.1f}%)")
print(f" - No asiste (0):    {n_no_asiste:,} ({n_no_asiste/len(pob_escolar)*100:.1f}%)")
```

Resultado: Población en edad escolar: 11,117 personas. De ellas, 5,170 asisten (46.5%) y 5,947 no asisten (53.5%). La clase está moderadamente desbalanceada, lo que justifica usar `class_weight="balanced"` en los modelos.

4.5 Ingeniería de características

Convertimos variables categóricas codificadas como 1/2 a binarias 0/1 estándar para facilitar el modelado posterior. Luego construimos variables derivadas a nivel hogar: hacinamiento, índice de servicios básicos, material de vivienda adecuado e internet.

```
# --- 1.6 Variables binarias ---
# Sexo binario: 1=Hombre, 0=Mujer
pob_escolar['sexo_bin'] = (pob_escolar['sexo'] == 1).astype(int)
# Indígena binario: 1=Sí, 0=No
pob_escolar['indigena_bin'] = (pob_escolar['indigena'] == 1).astype(int)
# Idioma materno originario (no español): 1=originario, 0=español
pob_escolar['idioma_originario'] = (
    (pob_escolar['idioma_materno'] != 1) & pob_escolar['idioma_materno'].notna()
).astype(int)
# Sabe leer y escribir (1=Sí, 0=No)
pob_escolar['lee_escribe_bin'] = (pob_escolar['lee_escribe'] == 1).astype(int)
# Trabajó (1=Sí, 0=No)
pob_escolar['trabajo_bin'] = (pob_escolar['trabajo'] == 1).astype(int)
```

```
# --- 1.7 Fusión con Vivienda ---
dataset = pob_escolar.merge(vivienda_sel, on='folio', how='left', suffixes=('_', '_viv'))
print(f"Dataset fusionado: {dataset.shape}")

# --- 1.8 Variables a nivel hogar ---
# Hacinamiento: personas por cuarto
dataset['n_cuartos'] = pd.to_numeric(dataset['n_cuartos'], errors='coerce')
dataset['totper'] = pd.to_numeric(dataset['totper'], errors='coerce')
dataset['hacinamiento'] = dataset['totper'] / dataset['n_cuartos'].replace(0, np.nan)
dataset['hacinamiento'] =
dataset['hacinamiento'].fillna(dataset['hacinamiento'].median())

# Índice de servicios básicos (0-3)
dataset['acceso_agua'] = dataset['procedencia_agua'].isin([1, 2, 3]).astype(int)
dataset['acceso_electricidad'] = (dataset['electricidad'] == 1).astype(int)
dataset['acceso_banio'] = (dataset['tipo_banio'].notna() &
    (dataset['tipo_banio'] != 6)).astype(int)
dataset['indice_servicios'] = (dataset['acceso_agua'] +
    dataset['acceso_electricidad'] +
    dataset['acceso_banio'])

# Material de vivienda
dataset['piso_adecuado'] = (~dataset['mat_piso'].isin([1])).astype(int)
dataset['pared_adecuada'] = dataset['mat_pared'].isin([1, 2, 4]).astype(int)
```

Proyecto elaborado Roger Choque Viscarra

```
dataset['internet_bin'] = (dataset['internet'] == 1).astype(int)

print("Variables a nivel hogar creadas: hacinamiento, indice_servicios,")
print(" piso_adequado, pared_adequada, internet_bin")
```

```
# --- 1.9 Variables del jefe/a de hogar ---
jefe_cols = ['folio', 'sexo', 'edad', 'nivel_educ', 'anios_estudio',
             'categoria_ocup', 'ingreso_lab']
persona_jefe = persona_sel[persona_sel['parentesco'] == 1][jefe_cols].rename(
    columns={c: f'jefe_{c}' for c in jefe_cols if c != 'folio'}
).drop_duplicates(subset='folio')
print(f"Jefes/as de hogar identificados: {len(persona_jefe):,}")

# Fusionar con dataset
dataset = dataset.merge(persona_jefe, on='folio', how='left')

# Ingreso per cápita del hogar
ingreso_hogar = persona_sel.groupby('folio')['ingreso_lab'].sum().reset_index()
ingreso_hogar.columns = ['folio', 'ingreso_total_hogar']
dataset = dataset.merge(ingreso_hogar, on='folio', how='left')
dataset['ingreso_percapita'] = dataset['ingreso_total_hogar'] / dataset['totper']
dataset['ingreso_percapita'] = dataset['ingreso_percapita'].fillna(0)
# Log-ingreso para el modelo (evitar sesgo por escala)
dataset['log_ingreso_pc'] = np.log1p(dataset['ingreso_percapita'].clip(lower=0))

# Educación del jefe/a
dataset['jefe_anios_estudio'] = pd.to_numeric(
    dataset['jefe_anios_estudio'], errors='coerce').fillna(0)

# --- 1.10 Mapeo final ---
depto_map = {1: 'Chuquisaca', 2: 'La Paz', 3: 'Cochabamba', 4: 'Oruro',
             5: 'Potosí', 6: 'Tarija', 7: 'Santa Cruz', 8: 'Beni', 9: 'Pando'}
dataset['depto_nombre'] = dataset['depto'].map(depto_map)
dataset['area_nombre'] = dataset['area'].map({1: 'Urbana', 2: 'Rural', 3:
'Urbana'})

print(f"\nDataset final: {dataset.shape}")
```

```
# --- 1.11 Guardar dataset_procesado.csv ---
output_csv = OUTPUTS_DIR / "dataset_procesado.csv"
dataset.to_csv(output_csv, index=False, encoding='utf-8')
print(f"Dataset guardado en: {output_csv}")
print(f"Tamaño: {output_csv.stat().st_size / 1024:.1f} KB")
```

5. Parte 2: Análisis Exploratorio y Visualización

En esta parte generamos **cuatro visualizaciones distintas** según lo requerido por la rúbrica: (1) gráfico de barras comparativo, (2) gráfico de relación edad-asistencia e ingreso, (3) mapa interactivo Folium, y (4) clustering K-means con PCA.

5.1 Cálculo de tasas agregadas

```
import folium
from folium.plugins import MarkerCluster
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

# --- 2.1 Tasas por departamento ---
tasas_depto = dataset.groupby('depto_nombre').agg(
    tasa_asistencia=('asistencia_escolar', 'mean'),
    n_estudiantes=('asistencia_escolar', 'count'),
    ingreso_pc_prom=('ingreso_percapita', 'mean'),
).reset_index()
tasas_depto['tasa_no_asistencia'] = 1 - tasas_depto['tasa_asistencia']
tasas_depto = tasas_depto.sort_values('tasa_no_asistencia', ascending=False)
print("Tasas por departamento:")
print(tasas_depto.to_string(index=False))
```

Las tasas departamentales revelan una fuerte heterogeneidad territorial:

Departamento	Tasa no asistencia	Tasa asistencia	N estudiantes	Ingreso pc (Bs)
Chuquisaca	75.8%	24.2%	792	1,727
Oruro	68.5%	31.5%	785	1,270
Tarija	66.4%	33.5%	769	1,933
Cochabamba	63.8%	36.2%	1,721	1,288
Beni	61.6%	38.4%	807	867
Potosí	57.8%	42.2%	829	988
Santa Cruz	55.5%	44.5%	2,150	1,007
Pando	47.1%	52.9%	741	1,293
La Paz	27.0%	73.0%	2,523	849

Nacional	53.5%	46.5%	11,117	1,156
----------	-------	-------	--------	-------

Tabla 1. Tasas de asistencia escolar por departamento. Fuente: EH2025 INE Bolivia, cálculo propio.

5.2 VISUALIZACIÓN 1: Gráfico de barras comparativo

Comparamos la tasa de no asistencia entre departamentos (panel izquierdo) y por zona × sexo (panel derecho). Esto permite identificar brechas territoriales y de género.

```
# --- 2.3 VISUALIZACIÓN 1: Gráfico de barras comparativo ---
fig, axes = plt.subplots(1, 2, figsize=(14, 5.5), constrained_layout=True)

# Subplot 1: por departamento
colors_depto = [PALETTE['danger'] if t > 0.55 else
                PALETTE['accent'] if t > 0.45 else
                PALETTE['secondary']
                for t in tasas_depto['tasa_no_asistencia']]
axes[0].barh(tasas_depto['depto_nombre'],
             tasas_depto['tasa_no_asistencia']*100,
             color=colors_depto, edgecolor='white', linewidth=1.2)
axes[0].set_xlabel('Tasa de no asistencia escolar (%)', fontsize=10)
axes[0].set_title('Deserción escolar por departamento\nBolivia, EH2025',
                  fontsize=11, fontweight='bold')
axes[0].axvline(tasas_depto['tasa_no_asistencia'].mean()*100,
                color=PALETTE['primary'], linestyle='--', linewidth=1,
                label=f'Promedio nacional: '
                    f'{tasas_depto["tasa_no_asistencia"].mean()*100:.1f}%')
axes[0].legend(fontsize=8, loc='lower right')
for i, (v, n) in enumerate(zip(tasas_depto['tasa_no_asistencia']*100,
                               tasas_depto['n_estudiantes'])):
    axes[0].text(v + 0.5, i, f'{v:.1f}%\n(n={n:,})', va='center', fontsize=8)
axes[0].set_xlim(0, max(tasas_depto['tasa_no_asistencia']*100) * 1.2)

# Subplot 2: por área y sexo
grp_sex_area = dataset.groupby(['area_nombre',
                               'sexo_bin'])['asistencia_escolar'].mean().unstack()
grp_sex_area.columns = ['Mujer', 'Hombre']
grp_sex_area = grp_sex_area.reindex(['Urbana', 'Rural'])
x_pos = np.arange(len(grp_sex_area))
w = 0.35
axes[1].bar(x_pos - w/2, (1 - grp_sex_area['Mujer'])*100, w, label='Mujer',
            color=PALETTE['accent'], edgecolor='white')
axes[1].bar(x_pos + w/2, (1 - grp_sex_area['Hombre'])*100, w, label='Hombre',
            color=PALETTE['primary'], edgecolor='white')
axes[1].set_xticks(x_pos)
axes[1].set_xticklabels(grp_sex_area.index)
axes[1].set_ylabel('Tasa de no asistencia (%)', fontsize=10)
```

```
axes[1].set_title('Deserción por zona y sexo\nBolivia, EH2025',
                  fontsize=11, fontweight='bold')
axes[1].legend(fontsize=9)
axes[1].set_ylim(0, 80)

fig.suptitle('Análisis comparativo de la deserción escolar – EH2025 Bolivia',
             fontsize=12, fontweight='bold', y=1.02)
plt.savefig(IMAGES_DIR / "01_barras_comparativas.png", dpi=150,
           bbox_inches='tight', facecolor='white')
plt.show()
```




Figura 1. Tasa de no asistencia escolar por departamento (izquierda) y por zona y sexo (derecha). La línea roja punteada indica el promedio nacional. Fuente: EH2025 INE Bolivia, cálculo propio.

El gráfico de barras horizontal revela tres grupos departamentales: **alto riesgo** (Chuquisaca, Oruro, Tarija con más de 65% de no asistencia), **riesgo medio** (Cochabamba, Beni, Potosí, Santa Cruz entre 55% y 65%) y **bajo riesgo** (Pando y La Paz con menos de 50%). Llama la atención que Tarija —departamento con ingreso per cápita promedio relativamente alto (1,933 Bs)— presente una tasa de no asistencia elevada, sugiriendo que el ingreso por sí solo no explica el fenómeno.

5.3 VISUALIZACIÓN 2: Relación edad-asistencia e ingreso

Analizamos cómo varía la tasa de asistencia con la edad del estudiante y cómo se distribuye el ingreso per cápita del hogar según la condición de asistencia.

```
# --- 2.4 VISUALIZACIÓN 2: Relación edad-asistencia e ingreso ---
fig, axes = plt.subplots(1, 2, figsize=(14, 5.5), constrained_layout=True)

# Subplot 1: tasa de asistencia por edad
edad_asist = dataset.groupby('edad')['asistencia_escolar'].agg(['mean',
'count']).reset_index()
axes[0].plot(edad_asist['edad'], edad_asist['mean']*100, marker='o',
             linewidth=2.2, markersize=8, color=PALETTE['primary'],
             markerfacecolor=PALETTE['accent'],
             markeredgecolor='white', markeredgewidth=1.5)
axes[0].fill_between(edad_asist['edad'], 0, edad_asist['mean']*100,
                    alpha=0.15, color=PALETTE['primary'])
axes[0].set_xlabel('Edad (años)', fontsize=10)
axes[0].set_ylabel('Tasa de asistencia escolar (%)', fontsize=10)
axes[0].set_title('Tasa de asistencia por edad\nTransición primaria → secundaria',
                  fontsize=11, fontweight='bold')
axes[0].grid(True, alpha=0.3)
axes[0].set_xticks(range(5, 20))
axes[0].axvspan(14, 19, alpha=0.1, color=PALETTE['danger'],
               label='Zona crítica (14-19 años)')
axes[0].legend(fontsize=8, loc='lower left')
axes[0].set_ylim(0, 110)

# Subplot 2: boxplot ingreso per cápita por asistencia
data_box = [dataset.loc[dataset['asistencia_escolar']==0, 'log_ingreso_pc'].values,
            dataset.loc[dataset['asistencia_escolar']==1, 'log_ingreso_pc'].values]
bp = axes[1].boxplot(data_box, labels=['No asiste', 'Sí asiste'],
                    patch_artist=True, widths=0.5, showfliers=False)
for patch, color in zip(bp['boxes'],
                        [PALETTE['danger'], PALETTE['secondary']]):
    patch.set_facecolor(color)
    patch.set_alpha(0.7)
axes[1].set_ylabel('Log(Ingreso per cápita del hogar)', fontsize=10)
axes[1].set_title('Distribución del ingreso del hogar\nsegún asistencia escolar',
                  fontsize=11, fontweight='bold')

fig.suptitle('Relación entre edad, ingreso y deserción escolar – EH2025 Bolivia',
             fontsize=12, fontweight='bold', y=1.02)
plt.savefig(IMAGES_DIR / "02_relacion_edad_ingreso.png", dpi=150,
           bbox_inches='tight', facecolor='white')
plt.show()
```




Figura 2. Tasa de asistencia escolar por edad (izquierda) y distribución del log-ingreso per cápita del hogar según asistencia (derecha). Fuente: EH2025 INE Bolivia, cálculo propio.

La curva de asistencia por edad muestra un patrón característico: tasas elevadas en la educación primaria (6-13 años), seguidas de un **descenso pronunciado a partir de los 14 años**, que coincide con la transición a la educación secundaria. Esta "curva de deserción" refleja tres fenómenos concurrentes: (i) la finalización de la primaria sin continuidad a secundaria, (ii) la incorporación al mercado laboral juvenil, y (iii) en el caso de las mujeres, embarazos adolescentes. La zona sombreada en rojo (14-19 años) identifica el grupo etario donde la política pública debe concentrar esfuerzos de retención.

El boxplot derecho evidencia una **clara diferencia en el ingreso del hogar** entre quienes asisten y no asisten. La mediana del log-ingreso per cápita es notablemente menor en hogares de estudiantes que no asisten, confirmando el papel del ingreso como factor protector. Sin embargo, la superposición de las cajas indica que el ingreso no es un predictor perfecto: hay hogares de ingreso medio-alto donde los menores tampoco asisten, y hogares de bajo ingreso donde sí lo hacen. Esta variabilidad residual es la que el modelo de Machine Learning intenta capturar.

5.4 VISUALIZACIÓN 3: Mapa interactivo Folium

Construimos un mapa interactivo de Bolivia con marcadores circulares por departamento. El tamaño del círculo es proporcional al número de estudiantes y el color indica el nivel de deserción. El archivo HTML interactivo se guarda en `outputs/mapa_desercion_departamental.html`.

```
# --- 2.5 VISUALIZACIÓN 3: Mapa interactivo Folium ---
# Coordenadas de capitales departamentales de Bolivia
depto_coords = {
    'La Paz': (-16.5000, -68.1500),
    'Santa Cruz': (-17.7833, -63.1821),
    'Cochabamba': (-17.3895, -66.1568),
    'Potosí': (-19.5836, -65.7531),
    'Oruro': (-17.9833, -67.1500),
    'Chuquisaca': (-19.0471, -65.2596),
    'Tarija': (-21.5333, -64.7333),
    'Beni': (-14.8333, -64.9000),
    'Pando': (-11.0333, -68.7667),
}

# Crear mapa centrado en Bolivia
m = folium.Map(location=[-16.5, -64.5], zoom_start=5, tiles='CartoDB positron')

for _, row in tasas_depto.iterrows():
    nombre = row['depto_nombre']
    if nombre in depto_coords:
        lat, lon = depto_coords[nombre]
        tasa_no = row['tasa_no_asistencia'] * 100
        radius = np.sqrt(row['n_estudiantes']) * 0.8
        if tasa_no > 60:
            color = PALETTE['danger']
        elif tasa_no > 50:
            color = PALETTE['accent']
        else:
            color = PALETTE['secondary']
        popup_text = f"<b>{nombre}</b><br>"\
            f"Tasa de no asistencia: <b>{tasa_no:.1f}%</b><br>"\
            f"Estudiantes: {row['n_estudiantes']:,}<br>"\
            f"Ingreso pc prom: {row['ingreso_pc_prom']:.0f} Bs"
        folium.CircleMarker(
            location=[lat, lon], radius=radius,
            popup=folium.Popup(popup_text, max_width=300),
            color=color, fill=True, fill_color=color,
            fill_opacity=0.6, weight=2,
        ).add_to(m)
```

Leyenda

```
legend_html = ""
```

```
<div style="position: fixed; bottom: 30px; left: 30px; z-index: 1000;
background: white; padding: 10px 14px; border-radius: 5px;
border: 2px solid #ccc; font-size: 11px;">
```

```
<p style="margin:0 0 6px 0; font-weight:bold;">Tasa de no asistencia</p>
```

```
<p><span style="color:#990000;">●</span> Alta (>60%)</p>
```

```
<p><span style="color:#B45F06;">●</span> Media (50-60%)</p>
```

```
<p><span style="color:#38761D;">●</span> Baja (<50%)</p>
```

```
<hr><p style="font-size:9px;color:#666;">Fuente: EH2025 - INE Bolivia</p>
```


```
</div>""
```

```
m.get_root().html.add_child(folium.Element(legend_html))
```

```
map_path = OUTPUTS_DIR / "mapa_desercion_departamental.html"
```

```
m.save(str(map_path))
```

```
print(f"Mapa guardado: {map_path}")
```



La visualización geográfica permite identificar **tres patrones territoriales**: (i) el **eje central-andino** (La Paz, Cochabamba) con mejores indicadores, posiblemente asociado a mayor oferta educativa y urbana; (ii) el **sur boliviano** (Chuquisaca, Tarija, Potosí) con tasas elevadas de deserción pese a no ser necesariamente los departamentos más pobres; y (iii) la **amazonía y llanos** (Beni, Pando, Santa Cruz) con situaciones heterogéneas. Estos patrones sugieren que las políticas educativas deben diferenciarse territorialmente y no aplicarse de manera uniforme a nivel nacional.

5.5 VISUALIZACIÓN 4: Clustering K-means

Aplicamos K-means ($k=3$) sobre los departamentos usando tres variables: tasa de no asistencia, ingreso per cápita promedio y número de estudiantes. Visualizamos con PCA 2D para identificar grupos naturales.

```
# --- 2.6 VISUALIZACIÓN 4: Clustering K-means ---
features_cluster = ['tasa_no_asistencia', 'ingreso_pc_prom', 'n_estudiantes']
X_cluster = tasas_depto[features_cluster].copy()
X_cluster['n_estudiantes'] = np.log1p(X_cluster['n_estudiantes'])
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_cluster)

# K-means con k=3
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
tasas_depto['cluster'] = kmeans.fit_predict(X_scaled)

# Etiquetar clusters según su perfil
cluster_profiles = tasas_depto.groupby('cluster').agg({
    'tasa_no_asistencia': 'mean',
    'ingreso_pc_prom': 'mean',
    'n_estudiantes': 'mean'
}).reset_index().sort_values('tasa_no_asistencia', ascending=False)

cluster_labels = {
    cluster_profiles.iloc[0]['cluster']: 'Riesgo alto',
    cluster_profiles.iloc[1]['cluster']: 'Riesgo medio',
    cluster_profiles.iloc[2]['cluster']: 'Riesgo bajo',
}
tasas_depto['cluster_label'] = tasas_depto['cluster'].map(cluster_labels)
```

```
# Visualización 2D con PCA
fig, axes = plt.subplots(1, 2, figsize=(15, 6), constrained_layout=True)

pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
cluster_colors = {'Riesgo alto': PALETTE['danger'],
                  'Riesgo medio': PALETTE['accent'],
                  'Riesgo bajo': PALETTE['secondary']}
for label in ['Riesgo alto', 'Riesgo medio', 'Riesgo bajo']:
    mask = tasas_depto['cluster_label'] == label
    axes[0].scatter(X_pca[mask, 0], X_pca[mask, 1], s=180,
                   c=cluster_colors[label], edgecolors='white',
                   linewidth=2, label=label, alpha=0.85, zorder=3)
for i, depto in enumerate(tasas_depto['depto_nombre']):
```

```
axes[0].annotate(depto, (X_pca[i, 0], X_pca[i, 1]),
                 xytext=(7, 5), textcoords='offset points',
                 fontsize=9, fontweight='bold')
axes[0].set_xlabel(f'PC1 ({{pca.explained_variance_ratio_[0]*100:.1f}}% varianza)')
axes[0].set_ylabel(f'PC2 ({{pca.explained_variance_ratio_[1]*100:.1f}}% varianza)')
axes[0].set_title('Clustering de departamentos (K-means, k=3)', fontweight='bold')
axes[0].legend(fontsize=9)
axes[0].grid(True, alpha=0.3)

# Tabla de clusters
axes[1].axis('off')
# ... (tabla con departamentos por cluster)
plt.savefig(IMAGES_DIR / "04_clustering_kmeans.png", dpi=150,
           bbox_inches='tight', facecolor='white')
plt.show()
```




Figura 3. Clustering de departamentos mediante K-means ($k=3$) sobre las variables tasa de no asistencia, ingreso per cápita y número de estudiantes. Visualización PCA 2D (izquierda) y tabla resumen (derecha).

Perfiles de clusters

Cluster	Departamentos	Tasa no asist. (prom.)	Caracterización
Riesgo alto	Chuquisaca, Tarija	71.1%	Tasas elevadas, ingreso medio. Intervención prioritaria.
Riesgo medio	Oruro, Beni, Potosí, Pando	58.8%	Situación intermedia, requiere monitoreo.
Riesgo bajo	Cochabamba, Santa Cruz, La Paz	48.8%	Mejores indicadores, aprender de buenas prácticas.

Tabla 2. Clusters departamentales según perfil de riesgo educativo.

6. Parte 3: Modelo de Machine Learning

6.1 Definición del problema y preparación de datos

Se entrenaron dos modelos supervisados para predecir la variable **asistencia_escolar** a partir de 19 variables predictoras (demográficas, geográficas, de vivienda, económicas y parentales). La división entrenamiento/prueba fue estratificada (80/20) para preservar la proporción de clases. Ambos modelos usaron ponderación de clases balanceada para mitigar el desbalanceo moderado de la variable objetivo.

```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import (accuracy_score, precision_score, recall_score,
                             f1_score, roc_auc_score, roc_curve,
                             confusion_matrix, ConfusionMatrixDisplay)

# Features finales para el modelo
feature_cols = [
    'edad', 'sexo_bin', 'indigena_bin', 'idioma_originario', 'lee_escribe_bin',
    'area_nombre', 'depto_nombre',
    'hacinamiento', 'indice_servicios', 'piso_adequado', 'pared_adequada',
    'internet_bin', 'log_alquiler',
    'log_ingreso_pc',
    'jefe_anios_estudio', 'jefe_edad', 'jefe_sexo',
    'trabajo_bin',
]
```

```
# Dataset para modelado
model_df = dataset[['asistencia_escolar'] + feature_cols].copy()
model_df['jefe_edad'] = pd.to_numeric(model_df['jefe_edad'],
                                     errors='coerce').fillna(model_df['jefe_edad'].median())
model_df['jefe_sexo'] = pd.to_numeric(model_df['jefe_sexo'],
                                     errors='coerce').fillna(1)

# One-hot encoding para categóricas
categorical_cols = ['area_nombre', 'depto_nombre']
model_df_encoded = pd.get_dummies(model_df, columns=categorical_cols,
                                  drop_first=True)
print(f"Dataset para modelado: {model_df_encoded.shape}")
print(f"Variables predictoras: {model_df_encoded.shape[1] - 1}")
```

```
# --- 3.2 División estratificada 80/20 ---
X = model_df_encoded.drop('asistencia_escolar', axis=1)
y = model_df_encoded['asistencia_escolar']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42, stratify=y
)
print(f"Train: {X_train.shape[0]:,} muestras (asiste={y_train.mean()*100:.1f}%)")
print(f"Test: {X_test.shape[0]:,} muestras (asiste={y_test.mean()*100:.1f}%)")

# Escalar para regresión logística
scaler_ml = StandardScaler()
X_train_scaled = scaler_ml.fit_transform(X_train)
X_test_scaled = scaler_ml.transform(X_test)
```

6.2 Modelo 1: Regresión Logística

Modelo lineal como baseline. Usamos `class_weight="balanced"` para mitigar el desbalanceo moderado de la variable objetivo.

```
# --- 3.3 Modelo 1: Regresión Logística ---
logreg = LogisticRegression(max_iter=1000, random_state=42,
                             class_weight='balanced')
logreg.fit(X_train_scaled, y_train)
y_pred_lr = logreg.predict(X_test_scaled)
y_proba_lr = logreg.predict_proba(X_test_scaled)[: , 1]
```

```
print("Regresión Logística:")
print(f" Accuracy: {accuracy_score(y_test, y_pred_lr):.4f}")
print(f" Precision: {precision_score(y_test, y_pred_lr):.4f}")
print(f" Recall: {recall_score(y_test, y_pred_lr):.4f}")
print(f" F1-score: {f1_score(y_test, y_pred_lr):.4f}")
print(f" AUC-ROC: {roc_auc_score(y_test, y_proba_lr):.4f}")
```

6.3 Modelo 2: Random Forest

Modelo de ensamble basado en árboles. Acepta variables no escaladas y captura interacciones no lineales. Hiperparámetros: 200 árboles, profundidad máxima 12, mínimo 20 muestras por hoja.

```
# --- 3.4 Modelo 2: Random Forest ---
rf = RandomForestClassifier(
    n_estimators=200, max_depth=12, min_samples_leaf=20,
    random_state=42, class_weight='balanced', n_jobs=-1
)
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)
y_proba_rf = rf.predict_proba(X_test)[:, 1]

print("Random Forest:")
print(f" Accuracy: {accuracy_score(y_test, y_pred_rf):.4f}")
print(f" Precision: {precision_score(y_test, y_pred_rf):.4f}")
print(f" Recall: {recall_score(y_test, y_pred_rf):.4f}")
print(f" F1-score: {f1_score(y_test, y_pred_rf):.4f}")
print(f" AUC-ROC: {roc_auc_score(y_test, y_proba_rf):.4f}")
```

6.4 Evaluación y comparación de modelos

Métrica	Regresión Logística	Random Forest	Interpretación
Accuracy	0.6331	0.6709	Precisión global del modelo
Precision	0.6288	0.6824	De los predichos como no asiste, cuántos realmente no asisten
Recall	0.5145	0.5464	De los que realmente no asisten, cuántos detecta el modelo
F1-score	0.5660	0.6069	Media armónica entre precision y recall
AUC-ROC	0.6730	0.7341	Capacidad discriminativa (0.5 = azar, 1.0 = perfecto)

Tabla 3. Comparación de métricas de desempeño de los dos modelos entrenados.

El **Random Forest** supera a la regresión logística en todas las métricas, con un AUC-ROC de **0.734** que indica una capacidad discriminativa aceptable (entre 0.7 y 0.8 según la convención académica). El recall de 0.546 indica que el modelo detecta aproximadamente el 55% de los casos reales de no asistencia, lo cual es operativamente útil para sistemas de alerta temprana, aunque deja margen de mejora. La precisión del 0.682 significa que cuando el modelo predice que un estudiante no asiste, acierta en el 68% de los casos.

```
# --- 3.6 VISUALIZACIÓN 5: Matrices de confusión y curva ROC ---
fig, axes = plt.subplots(1, 3, figsize=(16, 5), constrained_layout=True)

# Matriz confusión LR
cm_lr = confusion_matrix(y_test, y_pred_lr)
disp_lr = ConfusionMatrixDisplay(confusion_matrix=cm_lr,
                                display_labels=['No asiste', 'Sí asiste'])
disp_lr.plot(ax=axes[0], cmap='Blues', colorbar=False, values_format='d')
axes[0].set_title(f'Regresión Logística\nAccuracy: {accuracy_score(y_test,
y_pred_lr):.3f}',
                 fontsize=11, fontweight='bold')

# Matriz confusión RF
cm_rf = confusion_matrix(y_test, y_pred_rf)
disp_rf = ConfusionMatrixDisplay(confusion_matrix=cm_rf,
                                display_labels=['No asiste', 'Sí asiste'])
disp_rf.plot(ax=axes[1], cmap='Greens', colorbar=False, values_format='d')
axes[1].set_title(f'Random Forest\nAccuracy: {accuracy_score(y_test,
y_pred_rf):.3f}',
```

```

        fontsize=11, fontweight='bold')

# Curva ROC
fpr_lr, tpr_lr, _ = roc_curve(y_test, y_proba_lr)
fpr_rf, tpr_rf, _ = roc_curve(y_test, y_proba_rf)
axes[2].plot(fpr_lr, tpr_lr, color=PALETTE['primary'], linewidth=2,
             label=f'Regresión Logística (AUC = {roc_auc_score(y_test,
y_proba_lr):.3f}))')
axes[2].plot(fpr_rf, tpr_rf, color=PALETTE['secondary'], linewidth=2,
             label=f'Random Forest (AUC = {roc_auc_score(y_test,
y_proba_rf):.3f}))')
axes[2].plot([0, 1], [0, 1], 'k--', alpha=0.5, linewidth=1)
axes[2].set_xlabel('Tasa de Falsos Positivos', fontsize=10)
axes[2].set_ylabel('Tasa de Verdaderos Positivos', fontsize=10)
axes[2].set_title('Curva ROC – Comparación de modelos', fontsize=11,
fontweight='bold')
axes[2].legend(fontsize=9, loc='lower right')
axes[2].grid(True, alpha=0.3)

fig.suptitle('Evaluación de modelos predictivos de deserción escolar – EH2025
Bolivia',
            fontsize=12, fontweight='bold', y=1.02)
plt.savefig(IMAGES_DIR / "05_modelos_evaluacion.png", dpi=150,
            bbox_inches='tight', facecolor='white')
plt.show()

```




Figura 4. Matrices de confusión de la Regresión Logística (izquierda) y Random Forest (centro), y curva ROC comparativa (derecha). Fuente: EH2025 INE Bolivia, cálculo propio.

Las matrices de confusión muestran que el **Random Forest clasifica correctamente 1,497 casos** de un total de 2,224 en el conjunto de prueba (accuracy 67.1%). El modelo tiende a cometer más falsos negativos (predecir que asiste cuando en realidad no asiste) que falsos positivos, lo cual es esperable dada la mayor prevalencia de la clase "asiste" en ciertos subgrupos. Para aplicaciones de política pública, este sesgo hacia los falsos negativos puede ser

problemático porque implica que algunos estudiantes en riesgo no serían detectados por el sistema.

6.5 Importancia de variables

Extraemos las 10 variables más importantes del modelo Random Forest. La importancia se mide como la reducción promedio de impureza (Gini) acumulada por cada variable en todos los árboles del bosque.

```
# --- 3.7 Importancia de variables (Random Forest) ---
importancia = pd.DataFrame({
    'variable': X.columns,
    'importancia': rf.feature_importances_,
}).sort_values('importancia', ascending=False)

print("Top 15 variables más importantes:")
print(importancia.head(15).to_string(index=False))

# Etiquetas amigables
labels_map = {
    'edad': 'Edad del estudiante',
    'log_ingreso_pc': 'Log-ingreso per cápita hogar',
    'jefe_anios_estudio': 'Años de estudio del jefe/a',
    'hacinamiento': 'Hacinamiento (personas/cuarto)',
    'log_alquiler': 'Log-alquiler estimado (riqueza)',
    'indice_servicios': 'Índice de servicios básicos',
    'trabajo_bin': 'Estudiante trabaja',
    'internet_bin': 'Internet en el hogar',
    'lee_escribe_bin': 'Sabe leer y escribir',
    'jefe_edad': 'Edad del jefe/a de hogar',
    'depto_nombre_La Paz': 'Departamento La Paz',
    'depto_nombre_Chquisaca': 'Departamento Chuquisaca',
    # ... más etiquetas
}

top10 = importancia.head(10).copy()
top10['variable_label'] = top10['variable'].map(lambda x: labels_map.get(x, x))
```

```
# --- 3.8 VISUALIZACIÓN 6: Importancia de variables ---
fig, ax = plt.subplots(figsize=(11, 6.5), constrained_layout=True)
colors = [PALETTE['danger'] if i < 3 else
          PALETTE['accent'] if i < 6 else
          PALETTE['primary']
          for i in range(len(top10))]
bars = ax.barh(top10['variable_label'][::-1], top10['importancia'][::-1],
               color=colors[::-1], edgecolor='white', linewidth=1.5)
```

```
ax.set_xlabel('Importancia relativa (Random Forest)', fontsize=11)
ax.set_title('Top 10 variables predictoras de deserción escolar\nBolivia, EH2025',
             fontsize=12, fontweight='bold')
for bar, v in zip(bars, top10['importancia'][:-1]):
    ax.text(v + 0.002, bar.get_y() + bar.get_height()/2, f'{v:.3f}',
           va='center', fontsize=9, color='#333')
ax.grid(True, axis='x', alpha=0.3)

plt.savefig(IMAGES_DIR / "06_importancia_variables.png", dpi=150,
           bbox_inches='tight', facecolor='white')
plt.show()
```




Figura 5. Top 10 variables más importantes según el modelo Random Forest. La importancia se mide como la reducción promedio de impureza (Gini) acumulada por cada variable en todos los árboles del bosque.

El análisis de importancia de variables del Random Forest revela un hallazgo central: **la ubicación departamental es el factor predictivo dominante**, particularmente el hecho de residir en La Paz (importancia = 0.31). Esto confirma que la deserción escolar en Bolivia tiene una **dimensión territorial estructural** que va más allá de las características individuales del estudiante o de su hogar. Las políticas exclusivamente focalizadas en individuos (becas, transferencias condicionadas) pueden ser insuficientes si no se acompañan de intervenciones estructurales en los territorios con mayor deserción.

Los siguientes predictores en orden de importancia son: **ingreso per cápita del hogar**, **edad del jefe/a de hogar**, **años de estudio del jefe/a**, **hacinamiento**, **log-alquiler** (proxy de riqueza patrimonial), **edad del estudiante**, **índice de servicios básicos** y **trabajo del estudiante**. Esta jerarquía confirma la naturaleza multidimensional del fenómeno: ningún factor por sí solo explica la deserción, sino la confluencia de desventajas territoriales, económicas, familiares e individuales.

```
# --- 3.9 Guardar predicciones ---
predicciones = X_test.copy()
predicciones['asistencia_real'] = y_test.values
predicciones['pred_lr'] = y_pred_lr
predicciones['proba_lr'] = y_proba_lr
predicciones['pred_rf'] = y_pred_rf
predicciones['proba_rf'] = y_proba_rf
predicciones.to_csv(OUTPUTS_DIR / "predicciones.csv", index=False, encoding='utf-8')
print(f"Predicciones guardadas: {OUTPUTS_DIR / 'predicciones.csv'}")

# Guardar también tasas y comparación
tasas_depto.to_csv(OUTPUTS_DIR / "tasas_departamentales.csv", index=False)
comparison.to_csv(OUTPUTS_DIR / "comparacion_modelos.csv", index=False)
importancia.to_csv(OUTPUTS_DIR / "importancia_variables.csv", index=False)
print("\n✓ Parte 3 completada")
```

7. Parte 4: Hallazgos y Recomendaciones de Política Pública

7.1 Síntesis de hallazgos

El análisis aplicado a los microdatos de la EH2025 confirma que la deserción escolar en Bolivia es un fenómeno **multidimensional y territorialmente desigual**. La tasa nacional de no asistencia del 53.5% oculta brechas enormes entre departamentos: La Paz presenta la tasa más baja (27.0%) mientras Chuquisaca la más alta (75.8%), una diferencia de 48 puntos porcentuales que no puede explicarse únicamente por diferencias de ingreso. El modelo Random Forest alcanzó un AUC-ROC de 0.734, identificando como principales factores predictivos la ubicación departamental, el ingreso del hogar, los años de estudio del jefe/a y el hacinamiento. El clustering K-means agrupó los nueve departamentos en tres perfiles de riesgo, facilitando la focalización territorial de políticas educativas.

7.2 Recomendaciones de política pública

A partir de los hallazgos del análisis descriptivo, del clustering territorial y del modelo predictivo, se proponen **cinco recomendaciones concretas** de política pública, alineadas con el objetivo de reducir la deserción escolar en Bolivia. Estas recomendaciones se enmarcan en la Ley de la Educación N° 070 (2010) y en el Sistema Educativo Plurinacional Comunitario, sin sustituir sino complementar las políticas educativas vigentes.

Recomendación 1: Focalización territorial en clusters de riesgo alto

Implementar un **Plan Especial de Retención Escolar** en Chuquisaca y Tarija, los dos departamentos del cluster de riesgo alto (tasa de no asistencia superior al 66%). Este plan debe incluir: (i) diagnóstico cualitativo de barreras específicas (oferta educativa, calidad, distancia, factores culturales); (ii) fortalecimiento de la oferta de secundaria comunitaria en zonas rurales; (iii) sistemas de transporte escolar subsidiado; y (iv) programas de búsqueda activa de desertores con trabajadores sociales comunitarios. Se recomienda priorizar Chuquisaca por presentar la tasa más alta del país (75.8%).

Recomendación 2: Sistema de alerta temprana basado en Machine Learning

Desplegar el modelo Random Forest desarrollado en este estudio como parte de un **Sistema Nacional de Alerta Temprana de Deserción Escolar** integrado al sistema SIGE (Sistema de Información de Gestión Escolar) del Ministerio de Educación. El modelo identificaría estudiantes en riesgo al inicio de cada gestión escolar a partir de información sociodemográfica del SEB (Sistema Educativo Boliviano) y del Padrón Biométrico. Los directores y juntas escolares recibirían reportes mensuales con la lista de estudiantes en riesgo, con la obligación de activar protocolos de seguimiento. Se recomienda validación piloto en 3 municipios antes del escalamiento nacional.

Recomendación 3: Fortalecer el Bono Juancito Pinto con focalización predictiva

El Bono Juancito Pinto —transferencia condicionada de 1.000 Bs anuales por niño/a matriculado— es la política social educativa más consolidada del país. Sin embargo, su diseño universal no diferencia hogares con mayor riesgo de deserción. Se recomienda **modular el monto del bono** (doble o triple monto para estudiantes identificados por el modelo predictivo en riesgo alto), condicionado a la asistencia y rendimiento verificados. El costo fiscal estimado de esta ampliación es proporcional al subconjunto en riesgo (aproximadamente 15-20% de la población escolar) y podría financiarse con recursos del IDH o cooperación internacional.

Recomendación 4: Programa integral para la transición primaria-secundaria

El análisis por edad identifica una **caída crítica entre los 14 y 19 años**, coincidiendo con el paso de primaria a secundaria. Se recomienda implementar un **Programa de Acompañamiento a la Transición Secundaria** que incluya: (i) tutorías académicas personalizadas en 7°-8° primaria y 1°-2° secundaria; (ii) orientación vocacional temprana; (iii) becas de transporte y materiales para estudiantes rurales que deben migrar a cabeceras municipales para continuar secundaria; (iv) campañas contra el trabajo infantil en coordinación con el Ministerio de Trabajo; y (v) protocolos de retención de estudiantes embarazadas y madres adolescentes (Ley 263/2012).

Recomendación 5: Aprovechar las buenas prácticas de La Paz

La Paz presenta la **tasa de no asistencia más baja del país (27.0%)**, actuando como outlier positivo. Se recomienda realizar un **estudio cualitativo comparado** para identificar qué políticas, programas o prácticas específicas están funcionando en este departamento y que podrían replicarse. Hipótesis a verificar: (i) mayor cobertura de centros educativos estatales por densidad poblacional; (ii) efectividad del programa "La Paz Lee"; (iii) redes comunitarias y organizaciones sociales más activas en seguimiento escolar; (iv) menor incidencia de trabajo infantil urbano. La identificación de factores replicables puede informar el diseño de políticas en otros departamentos.

8. Conclusiones y Limitaciones

8.1 Conclusiones principales

Este estudio aplicó técnicas de Machine Learning y visualización de datos a los microdatos de la EH2025 para analizar la deserción escolar en Bolivia. Los hallazgos confirman que la deserción es un fenómeno **multidimensional y territorialmente desigual**: mientras La Paz presenta una tasa de no asistencia del 27.0%, Chuquisaca alcanza el 75.8%. El modelo Random Forest alcanzó un AUC-ROC de 0.734, identificando como principales factores predictivos la ubicación departamental, el ingreso del hogar, los años de estudio del jefe/a y el hacinamiento. El clustering K-means agrupó los nueve departamentos en tres perfiles de riesgo, facilitando la focalización territorial de políticas educativas.

Las recomendaciones de política pública se centran en cinco ejes: **focalización territorial** en Chuquisaca y Tarija, **sistema de alerta temprana** basado en el modelo predictivo, **modulación del Bono Juancito Pinto** según riesgo predictivo, **programa integral de**

transición primaria-secundaria para la franja 14-19 años, y **estudio cualitativo de buenas prácticas en La Paz**. Estas medidas, implementadas en coordinación entre el Ministerio de Educación, los gobiernos departamentales y municipales, y las organizaciones sociales, pueden contribuir significativamente a reducir la deserción escolar en Bolivia.

8.2 Limitaciones del estudio

- **Definición de deserción:** la variable objetivo combina no matriculación y deserción intra-anual, sin distinguirlas. Futuras investigaciones podrían separar ambos fenómenos.
- **Información ausente:** no se incorporaron variables de calidad educativa (PISA, ECE) ni de oferta (distancia a escuela, ratio docente-alumno), que podrían mejorar el poder predictivo.
- **Causalidad:** el análisis es correlacional. Las asociaciones identificadas no implican causalidad directa; se requieren diseños cuasi-experimentales para validar intervenciones.
- **Escalabilidad temporal:** la EH2025 es transversal. Un panel longitudinal permitiría modelar trayectorias escolares y patrones dinámicos de deserción.
- **Variabilidad subdepartamental:** el análisis se limita al nivel departamental por restricciones de muestra. Análisis municipales requieren mayor granularidad.

8.3 Trabajo futuro

Líneas de investigación futura incluyen: (i) incorporar variables cualitativas y de calidad educativa mediante fusión con otras fuentes; (ii) aplicar modelos más avanzados (Gradient Boosting, redes neuronales) con optimización bayesiana de hiperparámetros; (iii) desarrollar un panel longitudinal integrando EH 2018-2025; (iv) realizar análisis de fairness para verificar que el modelo no reproduzca sesgos por género, etnia o zona; y (v) validar el sistema de alerta temprana mediante un ensayo controlado aleatorizado en municipios piloto.

9. Citación y Fuente

Fuente de datos

Citación obligatoria: Instituto Nacional de Estadística, Encuesta de Hogares 2025 — <http://anda.ine.gob.bo/index.php/catalog/256>. Fecha de acceso: septiembre 2025.

Ética y privacidad

- Los microdatos de la EH2025 son **anonimizados** por el INE antes de su publicación.
- No se intenta reidentificar individuos ni hogares.
- El uso es **exclusivamente académico** y se cumple con los términos de acceso del ANDA.
- Este proyecto no almacena ni transmite información personal identificable.

Estructura del repositorio

```
Proyecto_EH2025_ML_Caso1/
├── data/                                # Microdatos originales (.sav)
│   └── EH2025
├── notebooks/
│   └── EH2025_Caso1_Google_Colab.ipynb    # Notebook principal
├── outputs/
│   └── Proyecto_EH2025_caso 1Desercion_Escolar Roger Choque Viscarra.pdf
# informe pdf (36 páginas)
├── predicciones.csv                    # Predicciones del modelo
├── dataset_procesado.csv                # Dataset final para modelado
├── mapa_desercion_departamental.html    # Mapa interactivo Folium
├── tasas_departamentales.csv
├── comparacion_modelos.csv
├── importancia_variables.csv
├── imagenes/                          # 6 visualizaciones PNG
├── docs/
│   └── README.md
└── requirements.txt
```

Requisitos técnicos

Paquete	Versión mínima	Uso
pandas	2.0+	Manipulación de datos
numpy	1.24+	Operaciones numéricas
pyreadstat	1.2+	Lectura de archivos .sav (SPSS)
scikit-learn	1.3+	Modelos ML, clustering, métricas
matplotlib	3.7+	Visualizaciones
seaborn	0.13+	Visualizaciones estadísticas

Proyecto elaborado Roger Choque Viscarra

folium	0.14+	Mapa interactivo
jupyter	1.0+	Ejecución del notebook

*Fuente: Instituto Nacional de Estadística, Encuesta de Hogares 2025 —
<http://anda.ine.gob.bo/index.php/catalog/256>. Fecha de acceso: septiembre 2025.*